

Propriedades Técnicas do Arquivo

Para assegurar o correto processamento em pipelines de Machine Learning, Engenharia de Dados e NLP, todos os textos seguem regras estruturais estritas:

- Tamanho Controlado: Cada documento possui menos de 300 palavras.
- Sanitização de Strings: Remoção completa de quebras de linha (\n) para garantir conformidade linear.
- Codificação Universal: Padrão UTF-8 nativo para preservar a acentuação gramatical em português.

Origem das Fontes por Domínio Temático (Tamanho original: 1k a 100k)

Esporte (IDs 1-5): Dataset AG News PT e Notícias GovBR (Hugging Face). Textos focados em crônicas esportivas, competições olímpicas e anúncios de comitês.

Tecnologia (IDs 6-10): Dataset AG News PT e Open-source LLM Prompts. Artigos sobre computação quântica, atualizações móveis e cibersegurança.

Saúde (IDs 11-15): Notas Oficiais da OMS e PubMed Abstracts (Hugging Face). Focado em pesquisas clínicas, nutrição e automação em triagens hospitalares.

Moda (IDs 16-20): Amazon Massive Scenario PT e Shopping Behavior (Kaggle). Textos sobre sustentabilidade têxtil, passarelas e brechós de luxo online.

Animais (IDs 21-25): Wikipedia Bio Datasets e Wildlife Ecology (Kaggle). Focado em comportamento de primatas, preservação de cetáceos e reservas ambientais.

Filme (IDs 26-30): IMDb Reviews PT-BR (Hugging Face). Críticas de cinema e análise sentimental de lançamentos de plataformas de streaming.

3. Tabela Estruturada dos 30 Documentos Traduzidos

ID	Tema	Documento (Texto Curto < 300 palavras)
1	Esporte	O atacante marcou dois gols na vitória decisiva de ontem à noite, garantindo a classificação do time para as quartas de final do campeonato nacional.
2	Esporte	A atleta brasileira quebrou o recorde sul-americano na prova dos 100 metros rasos durante o circuito mundial de atletismo em Paris.
3	Esporte	O comitê organizador dos jogos

		olímpicos anunciou novas diretrizes de segurança e venda de ingressos para a próxima temporada de competições de inverno.
4	Esporte	Após uma disputa emocionante no tie-break, o jovem tenista de dezenove anos conquistou seu primeiro título de Grand Slam na carreira.
5	Esporte	A equipe de basquete anunciou a contratação do novo treinador experiente, que promete focar a estratégia na defesa e no desenvolvimento de jovens talentos.
6	Tecnologia	A nova atualização do sistema operacional móvel trouxe melhorias significativas na autonomia da bateria e novos recursos avançados de privacidade de dados.
7	Tecnologia	Especialistas em segurança digital alertam para uma nova campanha de phishing que utiliza inteligência artificial para clonar a voz de executivos.
8	Tecnologia	O laboratório de pesquisa anunciou o desenvolvimento de um processador quântico capaz de resolver cálculos complexos em poucos segundos.
9	Tecnologia	Empresas de tecnologia estão investindo bilhões no desenvolvimento de assistentes virtuais integrados a modelos de linguagem de grande escala.
10	Tecnologia	O uso de redes neurais artificiais na indústria automobilística acelerou a homologação de sistemas de condução autônoma de nível quatro.
11	Saúde	Uma nova pesquisa clínica publicada nesta semana indica que a prática regular de exercícios moderados pode reduzir o risco de doenças cardíacas em até trinta por cento.

12	Saúde	A organização mundial da saúde iniciou uma nova campanha global de vacinação para erradicar variantes locais de doenças sazonais na África subsariana.
13	Saúde	Cientistas identificaram um novo marcador genético que pode ajudar no diagnóstico precoce e no tratamento personalizado de síndromes metabólicas de alta complexidade.
14	Saúde	O hospital universitário implementou um system de triagem baseado em aprendizado de máquina para reduzir o tempo de espera no pronto-socorro.
15	Saúde	Nutricionistas reforçam a importância de uma dieta equilibrada rica em alimentos integrais e gorduras saudáveis para a manutenção da microbiota intestinal.
16	Moda	A semana de moda de Milão destacou coleções focadas em sustentabilidade, utilizando tecidos reciclados e processos de tingimento ecológico.
17	Moda	O estilo retrô dos anos noventa continua influenciando as novas coleções de roupas urbanas e acessórios de grandes marcas internacionais.
18	Moda	Uma famosa estilista anunciou sua nova linha de alta costura inspirada na arquitetura brutalista e no uso de cores sóbrias e cortes assimétricos.
19	Moda	O crescimento do mercado de segunda mão e brechós online está mudando a forma como os consumidores jovens se relacionam com o consumo de luxo.
20	Moda	O uso de tecidos tecnológicos e inteligentes que regulam a temperatura corporal foi o grande destaque da feira de inovação têxtil deste ano.

21	Animais	Biólogos registraram um aumento significativo na população de baleias-jubarte na costa brasileira, indicando o sucesso das medidas de preservação ambiental.
22	Animais	Um novo estudo sobre o comportamento de primatas revelou que algumas espécies utilizam ferramentas de pedra complexas para abrir frutos rígidos.
23	Animais	O projeto de conservação conseguiu reintroduzir com sucesso dez espécimes de aves raras em seu habitat natural na floresta amazônica.
24	Animais	Pesquisadores descobriram que os cães possuem uma capacidade cognitiva avançada para interpretar expressões faciais humanas e variações no tom de voz.
25	Animais	Uma nova reserva marinha foi criada para proteger os santuários de reprodução de tartarugas marinhas ameaçadas de extinção no oceano pacífico.
26	Filme	O longa-metragem de ficção científica recebeu aclamação universal dos críticos em sua estreia mundial, sendo forte candidato às principais premiações do cinema.
27	Filme	O diretor premiado anunciou o início das filmagens de seu próximo drama histórico, que contará com um elenco repleto de estrelas consagradas.
28	Filme	A nova produção da plataforma de streaming bateu recordes de audiência no primeiro fim de semana, misturando elementos de suspense e terror psicológico.
29	Filme	O festival de cinema independente premiou um documentário contundente que aborda os impactos sociais da urbanização acelerada nas grandes metrópoles.

30	Filme	Críticos elogiaram a atuação impecável da atriz principal, que conseguiu transmitir profunda vulnerabilidade emocional sem o uso excessivo de diálogos.
----	-------	---

[27]
✓ Os

Se estiver executando no Google Colaboratory
if IN_COLAB:
!unzip -o -j -q "\$DIRETORIO_LOCAL\$NOME_ARQUIVO_DATASET_COMPACTADO" -d "\$DIRETORIO_LOCAL"

logging.info("Terminei a descompactação.")

INFO:root:Terminei a descompactação.

4.1.4 Carregamento dos dados do dataset

[28]
✓ Os

Import das bibliotecas.
import pandas as pd

Abre o arquivo e retorna o DataFrame
df_dataset = pd.read_csv(DIRETORIO_LOCAL + NOME_ARQUIVO_DATASET, sep=";", encoding="UTF-8")

logging.info("TERMINADO ORIGINAIS: {}".format(len(df_dataset)))

INFO:root:TERMINADO ORIGINAIS: 30.

[29]
✓ Os

df_dataset.sample(5)

1 to 5 of 5 entries ?

index	id	sentencas	documento
0	1	[O atacante marcou dois gols na vitória decisiva de ontem à noite, garantindo a classificação do time para as quartas de final do campeonato nacional.]	O atacante marcou dois gols na vitória decisiva de ontem à noite, garantindo a classificação do time para as quartas de final do campeonato nacional.
23	24	[Pesquisadores descobriram que os cães possuem uma capacidade cognitiva avançada para interpretar expressões faciais humanas e variações no tom de voz.]	Pesquisadores descobriram que os cães possuem uma capacidade cognitiva avançada para interpretar expressões faciais humanas e variações no tom de voz.
27	28	[A nova produção da plataforma de streaming bateu recordes de audiência no primeiro fim de semana, misturando elementos de suspense e terror psicológico.]	A nova produção da plataforma de streaming bateu recordes de audiência no primeiro fim de semana, misturando elementos de suspense e terror psicológico.
14	15	[Nutricionistas reforçam a importância de uma dieta equilibrada rica em alimentos integrais e gorduras saudáveis para a manutenção da microbiota intestinal.]	Nutricionistas reforçam a importância de uma dieta equilibrada rica em alimentos integrais e gorduras saudáveis para a manutenção da microbiota intestinal.
10	11	[Uma nova pesquisa clínica publicada nesta semana indica que a prática regular de exercícios moderados pode reduzir o risco de doenças cardíacas em até trinta por cento.]	Uma nova pesquisa clínica publicada nesta semana indica que a prática regular de exercícios moderados pode reduzir o risco de doenças cardíacas em até trinta por cento.

Show per page
Like what you see? Visit the [data table notebook](#) to learn more about interactive tables.

30

Corrigir o tipo de dados da lista das PoS-Tagging

Na lista pos:

- coluna 1 - pos_documento carregadas do arquivo vem como string e não como lista.

[37]
✓ Os

Import das bibliotecas.
import ast # Biblioteca para conversão de string em lista

Verifica se o tipo da coluna não é list e converte
df_dataset_pos["pos_documento"] = df_dataset_pos["pos_documento"].apply(lambda x: ast.literal_eval(x) if type(x)!=list else x)

logging.info("TERMINADO CORREÇÃO DOCUMENTOS POS: {}".format(len(df_dataset_pos)))

INFO:root:TERMINADO CORREÇÃO DOCUMENTOS POS: 30.

[38]
✓ Os

df_dataset_pos.sample(5)

1 to 5 of 5 entries ?

index	id	pos_documento
0	1	O atacante marcou dois gols na vitória decisiva de ontem à noite, garantindo a classificação do time para as quartas de final do campeonato nacional.,_DET,NOUN,VERB,NUM,NOUN,ADP,NOUN,ADJ,ADP,ADV,ADP,NOUN,PUNCT,VERB,DET,N
28	29	O festival de cinema independente premiou um documentário contundente que aborda os impactos sociais da urbanização acelerada nas grandes metrópoles.,_DET,NOUN,ADP,NOUN,ADJ,VERB,DET,NOUN,ADJ,PRON,VERB,DET,NOUN,ADJ,
4	5	A equipe de basquete anunciou a contratação do novo treinador experiente que promete focar a estratégia na defesa e no desenvolvimento de jovens talentos.,_DET,NOUN,ADP,NOUN,VERB,DET,NOUN,ADP,ADJ,NOUN,ADJ,PUNCT,PRON,VE
14	15	Nutricionistas reforçam a importância de uma dieta equilibrada rica em alimentos integrais e gorduras saudáveis para a manutenção da microbiota intestinal.,_NOUN,VERB,DET,NOUN,ADP,DET,NOUN,VERB,ADJ,ADP,NOUN,ADJ,CONN,NOUN
21	22	Um novo estudo sobre o comportamento de primatas revelou que algumas espécies utilizam ferramentas de pedra complexas para abrir frutos rígidos.,_DET,ADJ,NOUN,ADP,DET,NOUN,ADP,NOUN,VERB,SCONJ,DET,NOUN,VERB,NOUN,ADP,

Show per page
Like what you see? Visit the [data table notebook](#) to learn more about interactive tables.

from google.colab import data_table
import vega_datasets

data_table.enable_dataframe_formatter()

vega_datasets.data.airports()

1 to 25 of 3376 entries

Filter

index	iata	name	city	state	country	latitude	longitude
0	00M	Thigpen	Bay Springs	MS	USA	31.95379472	-89.23450472
1	00P	Livingston Municipal	Livingston	TX	USA	30.63681111	-95.01792778
2	00V	Meadow Lake	Colorado Springs	CO	USA	38.94674939	-104.5589933
3	01G	Perry-Warshaw	Perry	NY	USA	42.74134957	-78.05209058
4	01J	Hilliard Airport	Hilliard	FL	USA	30.880125	-81.90594389
5	01M	Tishomingo County	Belmont	MS	USA	34.49169667	-88.20111111
6	02A	Gragg-Wade	Clanton	AL	USA	32.85049957	-86.01145333
7	02C	Capitol	Brookfield	WI	USA	43.08751	-88.17789917
8	02G	Columbiana County	East Liverpool	OH	USA	40.87331278	-80.04140039
9	03D	Memphis Memorial	Memphis	MO	USA	40.44725889	-92.22690056
10	04M	Calhoun County	Pittsboro	MS	USA	33.63011222	-89.34285194
11	04Y	Hawley Municipal	Hawley	MN	USA	46.85384899	-95.35089891
12	05C	Griffin-Merriville	Griffin	IN	USA	41.51961917	-87.40109333
13	05F	Gatesville - City/County	Gatesville	TX	USA	31.42127556	-97.79696778
14	05U	Eureka	Eureka	NV	USA	39.00419957	-119.0050597
15	06A	Moton Municipal	Tuskegee	AL	USA	32.49047187	-85.88003811
16	06C	Schaumburg	Chicago/Schaumburg	IL	USA	41.98934083	-88.10124278
17	06D	Rolla Municipal	Rolla	ND	USA	48.88434111	-99.82087694
18	06M	Eupora Municipal	Eupora	MS	USA	33.53456583	-89.31259917
19	06N	Randall	Middletown	NY	USA	41.43156583	-74.39191722
20	06U	Jackpot-Hayden	Jackpot	NV	USA	41.97602222	-114.0550911
21	07C	Dekalb County	Auburn	IN	USA	41.30719567	-85.06433333
22	07F	Gladewater Municipal	Gladewater	TX	USA	32.52833961	-94.07174568
23	07G	Fish H Beach	Charlotte	ME	USA	42.57480891	-84.81143139
24	07K	Central City Municipal	Central City	NE	USA	41.11050505	-98.05033639

12

Show 25 per page

Abre o arquivo e retorna o DataFrame
df_dataset_ner = pd.read_csv(DIRETORIO_LOCAL + NOME_ARQUIVO_DATASET_NER, sep=";", encoding="UTF-8")

print(len(df_dataset_pos))

30

Corrigir o tipo de dados da lista das entidades

Na lista pos:

- coluna 1 - (ner_documento) carregadas do arquivo vem como string e não como lista.

Import das bibliotecas.
import ast # Biblioteca para conversão de string em lista

df_dataset_ner["ner_documento"] = df_dataset_ner["ner_documento"].apply(lambda x: ast.literal_eval(x) if type(x)!=list else x)

logging.info("TERMINADO CORREÇÃO DOCUMENTOS NER: {}".format(len(df_dataset_ner)))

INFO:root:TERMINADO CORREÇÃO DOCUMENTOS NER: 30.

df_dataset_ner.sample(5)

	id	ner_documento
26	27	[[0, []]]
8	9	[[0, []]]
28	29	[[0, []]]
1	2	[[0, [['Paris', 'LOC', 126, 130]]]]
15	16	[[0, [['Milão', 'LOC', 20, 25]]]]

```
for ent in doc.ents:
    print(ent.text, ent.start_char, ent.end_char, ent.label_)
```

ou

```
[(entity, entity.label_) for entity in doc.ents]
```

```
[]
```

Visualizando o texto marcado

```
# Importando as bibliotecas.
import spacy
from spacy import displacy

displacy.render(doc, style="ent", jupyter=True)
```

```
/usr/local/lib/python3.12/dist-packages/spacy/displycy/___init___py:215: UserWarning: [W006] No entities to visualize found in Doc object. If this is surprising to you, make sure the Doc was processed with a pipeline that includes a ner component.
warnings.warn(Warnings.W006)
```

O atacante marcou dois gols na vitória decisiva de ontem à noite, garantindo a classificação do time para as quartas de final do campeonato nacional.

5 Finalização

5.2.3.2 POS Tagging

<https://universallibraryofscience.org/docs4/pos/>

```
# Import das bibliotecas.
import pandas as pd

# Formata o número de casas decimais dos números reais
pd.set_option("display.precision", 2)

# Cria um DataFrame das estatísticas
dfstats_documentos_dic_pos = pd.DataFrame([getsonadic(x[1]) for x in stats_documentos_dic_pos])


# Exibe as estatísticas
dfstats_documentos_dic_pos.describe(include="all")
```

	PRON	VERB	PUNCT	DET	NUM	AUX	CCONJ	ADP	PRONPR	ADJ	ADV	NPR	SCONJ	SYM	SPACE	INTJ
count	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.0	30.0	30.0
mean	0.27	2.40	1.30	2.33	7.03	0.17	0.43	4.43	0.20	3.63	0.07	0.30	0.33	0.0	0.0	0.0
std	0.45	1.04	0.47	0.96	1.00	0.38	0.57	1.14	0.48	1.33	0.25	0.53	0.61	0.0	0.0	0.0
min	0.00	1.00	1.00	0.00	6.00	0.00	0.00	2.00	0.00	1.00	0.00	0.00	0.00	0.0	0.0	0.0
25%	0.00	2.00	1.00	2.00	6.00	0.00	0.00	4.00	0.00	3.00	0.00	0.00	0.00	0.0	0.0	0.0
50%	0.00	2.00	1.00	2.00	7.00	0.00	0.00	4.00	0.00	3.50	0.00	0.00	0.00	0.0	0.0	0.0
75%	0.75	3.00	2.00	3.00	8.00	0.00	1.00	5.00	0.00	5.00	0.00	0.75	0.75	0.0	0.0	0.0
max	1.00	4.00	2.00	4.00	9.00	1.00	2.00	7.00	2.00	6.00	1.00	2.00	2.00	0.0	0.0	0.0

Organiza os dados para gerar o boxplot

```
# Texto do eixo y
plt.ylabel("# Qtde")

# Mostra o gráfico
plt.show()
```



5.2.3.3 NER

```
1) # Import das bibliotecas.
import pandas as pd

# Formata o número de casas decimais dos números reais
pd.set_option("display.precision", 2)


# Cria um DataFrame das estatísticas
dfstats_documentos_dic_ner = pd.DataFrame([getstatistic(x[1]) for x in stats_documentos_dic_ner])

# Escreve as estatísticas
dfstats_documentos_dic_ner.describe(include="all")
```


```
***
      LOC  MISC  ONS  PER
count  30.00  30.00  30.00  30.0
mean   0.17   0.07   0.03   0.0
std    0.38   0.25   0.18   0.0
min    0.00   0.00   0.00   0.0
25%    0.00   0.00   0.00   0.0
50%    0.00   0.00   0.00   0.0
75%    0.00   0.00   0.00   0.0
max    1.00   1.00   1.00   0.0
```



```
plt.show()
```




```
# Mostra o gráfico  
plt.show()
```



Quantidade de NER nos documentos

```
# Import das bibliotecas.  
import matplotlib.pyplot as plt  
import seaborn as sns  
import numpy as np  
  
sns.set(style="darkgrid")  
  
# Aumenta o tamanho da plotagem e o tamanho da fonte.  
plt.rcParams["figure.figsize"] = (20,10)  
  
# Lista em ordem crescente os dados  
order = df['tokens_ner'].value_counts(ascending=False).index  
  
# Plota o número de tokens de cada tamanho  
ax = sns.countplot(x="tokens_ner", data=df, order=order)  
  
# Adiciona os valores as colunas  
for p in ax.patches:  
    ax.annotate(f"{p.get_height()}", (p.get_x()+0.2, p.get_height()+1))  
  
plt.title("Quantidade de entidades nos documentos")  
plt.xlabel("#Classe entidade")  
plt.ylabel("#Quantidade")  
  
plt.show()
```



5.2.4 Por sentença


5.2.4.1 Gerais

```
# Import das bibliotecas.
import pandas as pd

# Formata o número de casas decimais dos números reais
pd.set_option("display.precision", 2)

# Cria um Dataframe das estatísticas
df_stats = pd.DataFrame(data=stats.sentences)
df_stats.describe(include="all")
```

	Id	sentença	qtdepalavras	qtde tokens bert	qtdepalavras menos stopwords	qtde locução verbal	qtde verbo	qtde verbo aux	qtde substantivo	qtde verbo aux + substantivo	qtde palavras desconhecidas	qtde ner
count	30.00	30.0	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00
mean	15.90	0.0	22.90	27.30	13.80	2.17	2.40	2.57	7.03	9.60	3.23	0.27
std	8.80	0.0	1.99	2.58	1.32	0.95	1.04	1.01	1.00	1.22	1.65	0.45
min	1.00	0.0	20.00	21.00	11.00	1.00	1.00	1.00	6.00	7.00	1.00	0.00
25%	8.25	0.0	22.00	25.25	13.00	1.25	2.00	2.00	6.00	9.00	2.00	0.00
50%	15.50	0.0	22.00	28.00	14.00	2.00	2.00	2.00	7.00	10.00	3.00	0.00
75%	22.75	0.0	24.00	29.00	15.00	3.00	3.00	3.00	8.00	10.75	4.00	0.75
max	30.00	0.0	28.00	34.00	17.00	4.00	4.00	4.00	9.00	11.00	8.00	1.00



5.2.4.2 POS Tagging

<https://universaldependencies.org/focus/upos/>


```
# Import das bibliotecas.
import pandas as pd

# Formata o número de casas decimais dos números reais
pd.set_option("display.precision", 2)

# Cria um DataFrame das estatísticas
df_stats_sentencas_dic_pos = pd.DataFrame([getSomaDic([x[2]] for x in stats_sentencas_dic_pos)])

# Exibe as estatísticas
df_stats_sentencas_dic_pos.describe()
```

	PRON	VERB	PUNCT	DET	NOUN	AUX	CCONJ	ADP	PROPN	ADJ	ADV	NUM	SCONJ	SYM	SPACE	INTJ
count	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00	30.00
mean	0.27	2.40	1.30	2.33	7.03	0.17	0.43	4.43	0.20	3.63	0.07	0.30	0.33	0.0	0.0	0.0
std	0.45	1.04	0.47	0.96	1.00	0.38	0.57	1.14	0.48	1.33	0.25	0.53	0.61	0.0	0.0	0.0
min	0.00	1.00	1.00	0.00	6.00	0.00	0.00	2.00	0.00	1.00	0.00	0.00	0.00	0.0	0.0	0.0
25%	0.00	2.00	1.00	2.00	6.00	0.00	0.00	4.00	0.00	3.00	0.00	0.00	0.00	0.0	0.0	0.0
50%	0.00	2.00	1.00	2.00	7.00	0.00	0.00	4.00	0.00	3.50	0.00	0.00	0.00	0.0	0.0	0.0
75%	0.75	3.00	2.00	3.00	8.00	0.00	1.00	5.00	0.00	5.00	0.00	0.75	0.75	0.0	0.0	0.0
max	1.00	4.00	2.00	4.00	9.00	1.00	2.00	7.00	2.00	6.00	1.00	2.00	2.00	0.0	0.0	0.0



```
# Import das bibliotecas.
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

sns.set(style="darkgrid")

# Aumenta o tamanho da plotagem e o tamanho da fonte.
plt.rcParams["figure.figsize"] = (20,10)

df_pos = df_stats_sentencas_dic_pos[df_stats_sentencas_dic_pos["pos"].isin(["NOUN","VERB","AUX"])]

# Plota o número de tokens de cada tamanho
ax = sns.countplot(x="qtde",hue="pos", data=df_pos)


# Adiciona os valores as colunas
for p in ax.patches:
    ax.annotate('{0:g}'.format(p.get_height()), (p.get_x()+0.1, p.get_height()+0.1))

plt.title("Quantidade de ocorrências de classes morfosintática por sentença")
plt.xlabel("#Ocorrências por sentença")
plt.ylabel("#Sentenças")

# Insere a legenda e por padrão usa o label de cada gráfico em duas colunas na parte inferior
plt.legend(title='Legenda:', loc='upper right', fontsize=12, _legend_box.align='left')

plt.show()
```

INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
 INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



5.2.4.3 Gráficos de POS Tagging nas sentenças dos documentos

```
# Import das bibliotecas.
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

sns.set(style="darkgrid")

# Aumenta o tamanho da plotagem e o tamanho da fonte.
plt.rcParams["figure.figsize"] = (20,10)


# Plota o número de tokens de cada tamanho
ax = sns.countplot(x=[f"qtde" for i, f in df_stats_sentencas_dic_pos.iterrows() if f["pos"]=="VERB"])


# Adiciona os valores as colunas
for p in ax.patches:
    ax.annotate(f"{p.get_height()}", (p.get_x()+0.35, p.get_height()+0.2))

plt.title("Quantidade de VERB por sentença")
plt.xlabel("#Qtde de VERB")
plt.ylabel("#Sentenças")

plt.show()
```

INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
 INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.





```
# Import das bibliotecas.
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

sns.set(style="darkgrid")

# Aumenta o tamanho da plotagem e o tamanho da fonte.
plt.rcParams["figure.figsize"] = (20,10)


# Plota o número de tokens de cada tamanho
ax = sns.countplot(x=[f"#Qtde" for i, f in df_stats_sentencas_dic_pos.iterrows() if f["pos"]=="NOUN"])

# Adiciona os valores as colunas
for p in ax.patches:
    ax.annotate(f"{p.get_height()}", (p.get_x()+0.3, p.get_height()+0.2))


plt.title("Quantidade de NOUN por sentença")
plt.xlabel("#Qtde de NOUN")
plt.ylabel("#Sentenças")

plt.show()
```


INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.




INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



5.2.4.4 NER

```
# Import das bibliotecas.
import pandas as pd

# Formata o número de casas decimais dos números reais
pd.set_option("display.precision", 2)

# Cria um DataFrame das estatísticas
df_stats_sentencas_dic_ner = pd.DataFrame([getSomaDic([x[2]]) for x in stats_sentencas_dic_ner])


# Exibe as estatísticas
df_stats_sentencas_dic_ner.describe()
```

	LOC	MISC	ORG	PER
count	30.00	30.00	30.00	30.0
mean	0.17	0.07	0.03	0.0
std	0.38	0.25	0.18	0.0
min	0.00	0.00	0.00	0.0
25%	0.00	0.00	0.00	0.0
50%	0.00	0.00	0.00	0.0
75%	0.00	0.00	0.00	0.0
max	1.00	1.00	1.00	0.0

```
# Converte os dados para o boxplot
```


```
plt.show()
```

INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
 INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.




Ex.: Existe 4(#Sentenças) sentenças onde palavras da classe morfosintática LOC(azul legenda) ocorrem uma vez(#Ocorrências por


*** INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



*** INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



5.2.5.3 Estatísticas palavras e tokens por janela

```
# Import das bibliotecas.
import pandas as pd

# Formata o número de casas decimais dos números reais
pd.set_option("display.precision", 2)

# Cria um DataFrame das estatísticas
dfstats_janelas = pd.DataFrame(data=stats_janelas)

dfstats_janelas.describe(include="all")
```

	id	qtdepalavras	qtdetokensbert	qtdepalavrasjanela3	qtdepalavrasjanela5	qtdetokenbertjanela3	qtdetokenbertjanela5
count	30.00	30.00	30.00	30.00	30.00	30.00	30.00
mean	15.50	22.90	27.30	22.90	22.90	27.30	27.30
std	8.80	1.99	2.58	1.99	1.99	2.58	2.58
min	1.00	20.00	21.00	20.00	20.00	21.00	21.00
25%	8.25	22.00	25.25	22.00	22.00	25.25	25.25
50%	15.50	22.00	28.00	22.00	22.00	28.00	28.00
75%	22.75	24.00	29.00	24.00	24.00	29.00	29.00
max	30.00	28.00	34.00	28.00	28.00	34.00	34.00

5.2.5.4 Estatísticas palavras e tokens em janelas por documento

```
# Import das bibliotecas.
import pandas as pd

# Formata o número de casas decimais dos números reais
pd.set_option("display.precision", 2)

# Cria um DataFrame das estatísticas
dfstats_documentos_janela = pd.DataFrame(data=stats_documento_janelas)


dfstats_documentos_janela.describe(include="all")
```

	id	qtdepalavras	qtdetokensbert	totalpalavrasjanela3	totalpalavrasjanela5	totaltokenbertjanela3	totaltokenbertjanela5
count	30.00	30.00	30.00	30.00	30.00	30.00	30.00
mean	15.50	1.0	22.90	27.30	22.90	27.30	27.30
std	8.80	0.0	1.99	2.58	1.99	2.58	2.58
min	1.00	1.0	20.00	21.00	20.00	20.00	21.00
25%	8.25	1.0	22.00	25.25	22.00	22.00	25.25
50%	15.50	1.0	22.00	28.00	22.00	22.00	28.00
75%	22.75	1.0	24.00	29.00	24.00	24.00	29.00
max	30.00	1.0	28.00	34.00	28.00	28.00	34.00



INFO:matplotlib.category:using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.




INFO:matplotlib.category:using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.




INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.






INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.

INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.




INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.





INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



```

# Import das bibliotecas
import matplotlib.pyplot as plt
import seaborn as sns

sns.set(style='darkgrid')

# Aumenta o tamanho da plotagem e o tamanho da fonte.
sns.set(font_scale=1.5)
plt.rcParams["figure.figsize"] = (12,6)

# Adiciona os valores as colunas
plt.scatter(range(0, len(tamanhos_sentencas)), tamanhos_sentencas, marker="|")

plt.xlabel("#Documento")
plt.ylabel("#tamanho documentos")
plt.title("Tamanhos dos documentos tokenizados antes de classificar")

plt.show()

```




```


# Import das bibliotecas

```


INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
 INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.




*** INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



```
[ ] ▶ # Import das bibliotecas.
import pandas as pd

# Formata o número de casas decimais dos números reais
pd.set_option("display.precision", 2)

# Cria um DataFrame das estatísticas
dfstats_janelas = pd.DataFrame(data=stats_janelas)

dfstats_janelas.describe(include="all")
```

```
▼ ***
```

	id	qtdepalavras	qtdetokensbert	qtdepalavrasjanela3	qtdepalavrasjanela5	qtdetokenbertjanela3	qtdetokenbertjanela5
count	30.00	30.00	30.00	30.00	30.00	30.00	30.00
mean	15.50	22.90	27.30	22.90	22.90	27.30	27.30
std	8.80	1.99	2.58	1.99	1.99	2.58	2.58
min	1.00	20.00	21.00	20.00	20.00	21.00	21.00
25%	8.25	22.00	25.25	22.00	22.00	25.25	25.25
50%	15.50	22.00	28.00	22.00	22.00	28.00	28.00
75%	22.75	24.00	29.00	24.00	24.00	29.00	29.00
max	30.00	28.00	34.00	28.00	28.00	34.00	34.00

5.2.5.3 Estatísticas palavras e tokens por janela

```
# Import das bibliotecas.
import pandas as pd

# Formata o número de casas decimais dos números reais
pd.set_option("display.precision", 2)

# Cria um DataFrame das estatísticas
dfstats_janelas = pd.DataFrame(data=stats_janelas)

dfstats_janelas.describe(include="all")
```


```
***
      id  qtdepalavras  qdtokensbert  qtdepalavrasjanela3  qtdepalavrasjanela5  qdtokensbertjanela3  qdtokensbertjanela5
count  30.00         30.00         30.00         30.00         30.00         30.00         30.00
mean   15.50         22.90         27.30         22.90         22.90         27.30         27.30
std     8.80          1.99          2.58          1.99          1.99          2.58          2.58
min     1.00         20.00         21.00         20.00         20.00         21.00         21.00
25%     8.25         22.00         25.25         22.00         22.00         25.25         25.25
50%    15.50         22.00         28.00         22.00         22.00         28.00         28.00
75%    22.75         24.00         29.00         24.00         24.00         29.00         29.00
max    30.00         28.00         34.00         28.00         28.00         34.00         34.00
```

```
plt.show()
```

INFO:matplotlib.category:using categorical units to plot a list of strings that are all parsable as floats or dates. if these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:using categorical units to plot a list of strings that are all parsable as floats or dates. if these strings should be plotted as numbers, cast to the appropriate data type before plotting.




INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.




plt.show()

INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.




```
plt.show()
```

INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.




```
plt.show()
```

INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



```
# Import das bibliotecas
import matplotlib.pyplot as plt
import seaborn as sns

sns.set(style='darkgrid')

# Aumenta o tamanho da plotagem e o tamanho da fonte.
sns.set(font_scale=1.5)
plt.rcParams["figure.figsize"] = (12,6)

# Adiciona os valores as colunas
plt.scatter(range(0, len(tamanhos_sentencas)), tamanhos_sentencas, marker="|")

plt.xlabel("#Documento")
plt.ylabel("#Tamanho documentos")
plt.title("Tamanhos dos documentos tokenizados antes de classificar")

plt.show()
```



Comece a programar ou gere código com IA.

```
# Import das bibliotecas
import matplotlib.pyplot as plt
import seaborn as sns


# Use plot styling from seaborn.
sns.set(style='darkgrid')

# Increase the plot size and font size.
sns.set(font_scale=1.5)
plt.rcParams["Figure.figsize"] = (12,6)



plt.scatter(range(0, len(tamanhos_sentencas)), sorted(tamanhos_sentencas), marker="|")

plt.xlabel("#Documento")
plt.ylabel("#Tamanho documentos")
plt.title("Tamanhos dos documentos tokenizados classificados")


plt.show()
```



INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.




```
''' INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
```




```
plt.ylabel("#Sentenças")
plt.show()
```

```
''' INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
```




INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.





```
plt.ylabel("#Sentenças")  
plt.show()
```


INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



INFO:matplotlib.category:using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.
INFO:matplotlib.category:Using categorical units to plot a list of strings that are all parsable as floats or dates. If these strings should be plotted as numbers, cast to the appropriate data type before plotting.



[Código](#) [Texto](#)

6 Finalização

6.1 Tempo final de processamento

```
13 # Pega o tempo atual menos o tempo do início do processamento.  
#final_processamento = time.time()  
tempo_total_processamento = format(tempo(final_processamento - inicio_processamento))  
  
print("")  
print(" Tempo processamento: {:.1} (h:mm:ss)".format(tempo_total_processamento))
```

Tempo processamento: 0:03:49 (h:mm:ss)